FLINK FORWARD #ASIA 2021 ONLINE

实时即未来 REAL-TIME IS THE FUTURE

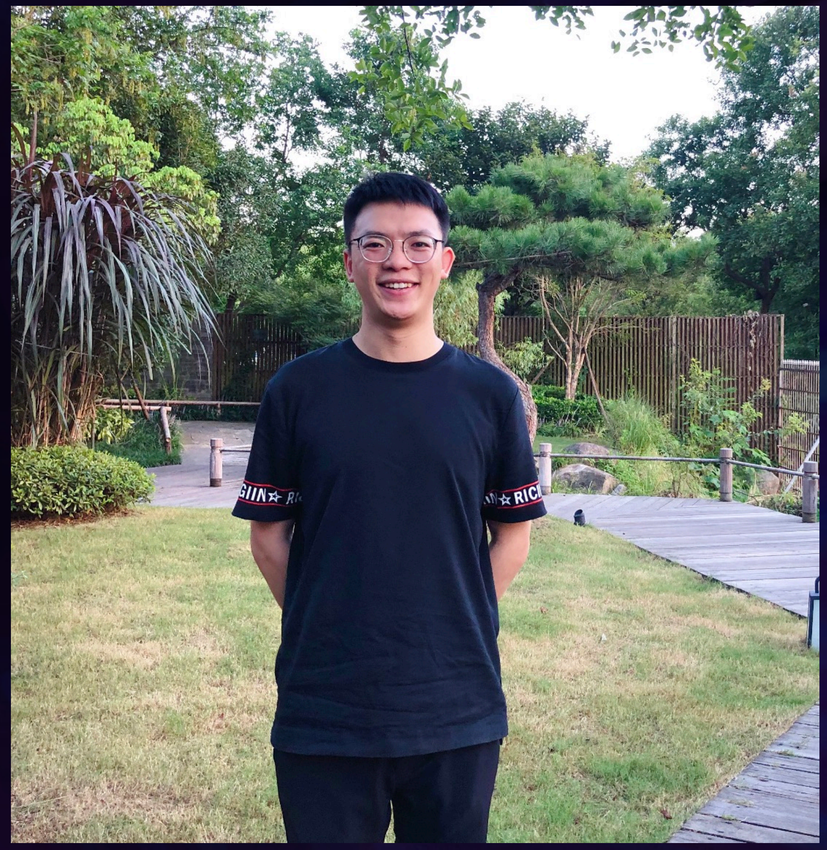
阿里超大规模 Flink 集群运维体系介绍

王华 阿里云实时计算高级运维专家

自我介绍

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

- 花名 @尚付，阿里云-计算平台-大数据实时计算运维负责人
- 自2015年起，一直专注于开源大数据实时计算运维，完整经历了阿里巴巴实时计算发展全过程。负责超大规模实时计算集群架构演进、运维体系建设以及运维产品打造



阿里实时计算运维

#1
演进历史和
运维挑战

#2
集群运维
Flink Cluster

#3
应用运维
Flink Job

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

#1 演进历史和运维挑战

阿里实时计算平台演进历史

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

1.0 时代 2013-2017
三大实时计算引擎并存时代（Galaxy/Jstorm/Blink）

2.0 时代 2017-2021
Blink为唯一实时计算引擎大一统时代（ALL On Blink）

3.0 时代 2021 -
Flink开源新引擎搭载云原生的新时代（VVP新平台）



平台架构正从云下架构（Hadoop+Blink）全面往云原生架构（K8S+Flink）大规模演进中

阿里实时计算平台规模和技术架构经历了近十年的快速发展

实时计算运维挑战

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

平台运维

解决SRE超大规模体量的平台（Flink Cluster）运维难题

应用运维

帮助实时计算用户，解决复杂的应用（Flink Job）运维难题

云原生&智能运维演进

云原生&AI智能化大浪潮下，运维演进和能力提升

运维经历的三大挑战

#2 集群运维 Flink Cluster

超大规模Flink集群的稳定性难题



业务场景既重要且实时敏感

Flink承载了阿里内部全部实时数据业务，包括双11 GMV媒体大屏、阿里妈妈广告计量计费报警、搜索推荐机器学习平台等电商核心业务场景

平台规模大，局部异常是常态

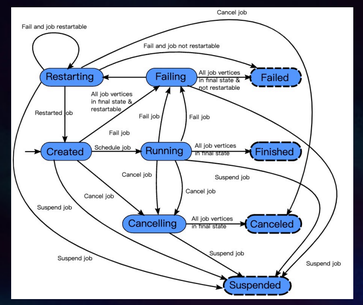
几万台独享机器、多地域&多集群布局，规模体量飞增天然带来的平台部署形态复杂，局部异常是常态。

业务重要且敏感，平台规模大架构复杂，稳定性双重叠加挑战

Flink Cluster SLA

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

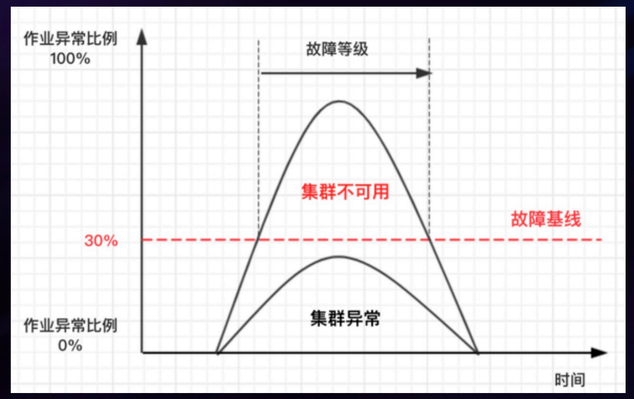
Flink Cluster SLI



- 调度：JM和TM启动中
- 运行：JM和TM都正常运行
- 异常：JM或TM FailOver

Flink Job复杂状态抽象成三种简单状态代表SLI

Flink Cluster SLO



Cluster SLA （99.99x%）
分钟级可用率来精细化度量集群稳定性

SLA 异常次数 ✖ SLA 异常时长/次 ➡ Cluster SLA

- 做好预防，减少SLA异常次数
- 做好快恢，缩短SLA异常时长

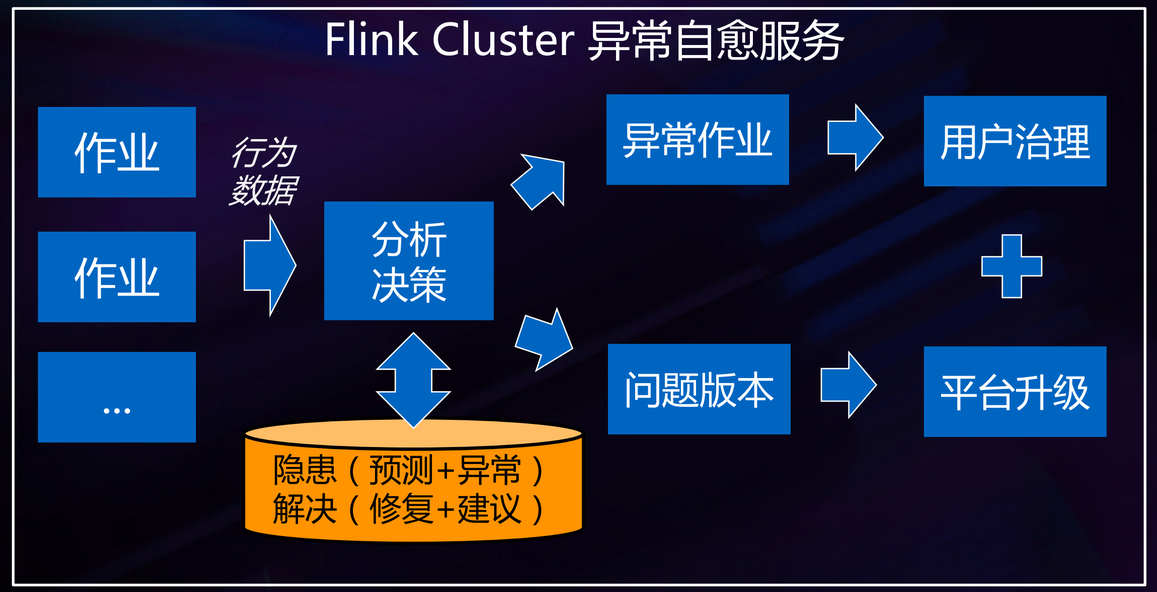
SLA可用率精细度量Flink Cluster稳定性

集群巡检治理，减少SLA异常次数

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

导致集群异常的“棘手”场景

- *e.g. 批量机器Load高/磁盘打满，导致集群大量作业心跳丢失异常*
- *e.g. 存储集群容量/请求队列打满，导致集群大量作业CPT超时异常*
- *e.g. 某个版本存在性能/稳定性重大Bug，影响了集群近百个作业*
- *...*



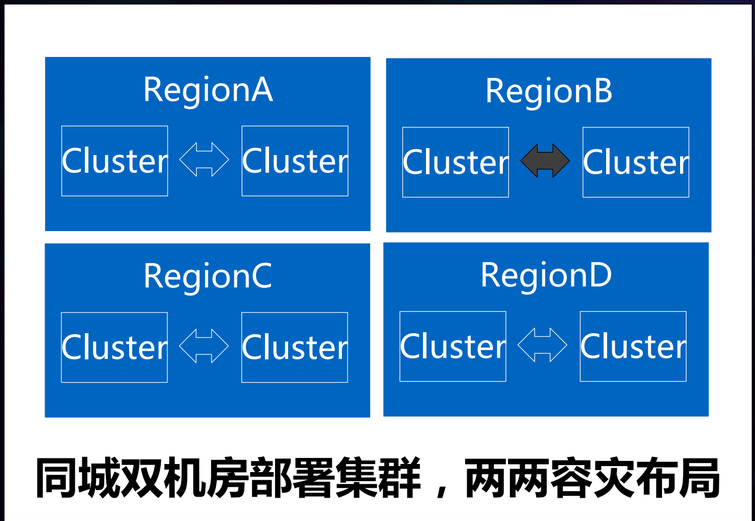
沉淀了几十种业务侧最高频的异常规则及治理方案
全自动化识别、消灭之前“看不见”隐患

模块	诊断项	治理规则	整治频率
Blink	state backend配置错误	x作业state backend配置为rocksdb	3d
	长期连续failover	连续failover超过 h，即每小时至少failover一次	24h
	短期频繁failover	小时内failover的container数量大于w	6h
	单container cpu超用过多	单container使用超申请 倍以上	24h
	app重启次数过多	当天app连续killed超过 次	h
	非稳定版本	版本过保或者加黑	d
ZK	ZK连接数过大	单作业zk连接数 > w	min
YARN	pending container持续增长	pending container持续增加，并且超过 w	min
	AM长期连续failover	AM连续failover超过 h，至少failover 次	24h
	AM短期频繁failover	AM最近6h failover 超过 次	6
HDFS	state写入速度太快	state数据较大并且两次cpt之间时间间隔较短，平均写入速度大于 /s	4h
	作业state占用hdfs空间太大	单个作业的state占用的物理空间大于 P	3
OS	线程数过大	单container线程数大于 w	24h

稳定性预防

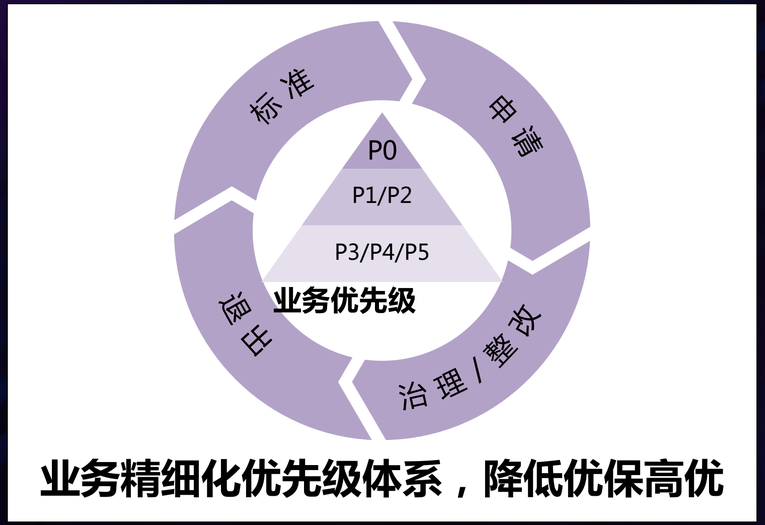
集群切流容灾，缩短SLA异常时长

挑战：集群级重大故障均表现定位难，耗时久，稳定性极其被动



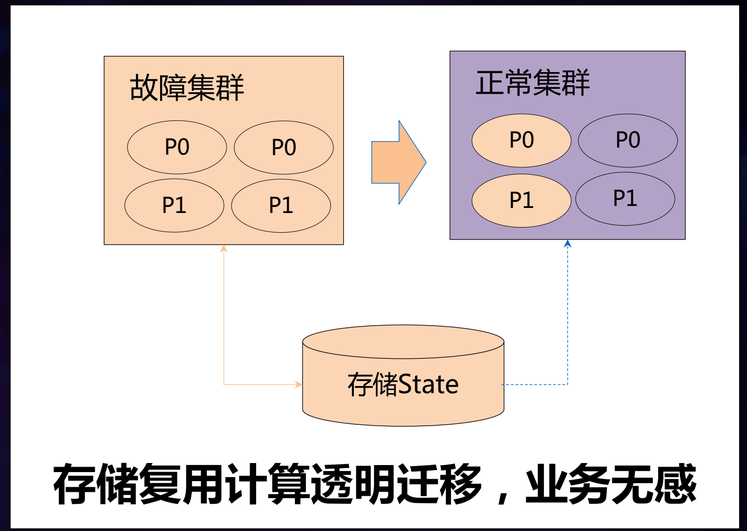
同城双机房部署集群，两两容灾布局

1. 往哪里切流？



业务精细化优先级体系，降低优保高优

2. 资源有限，切谁？

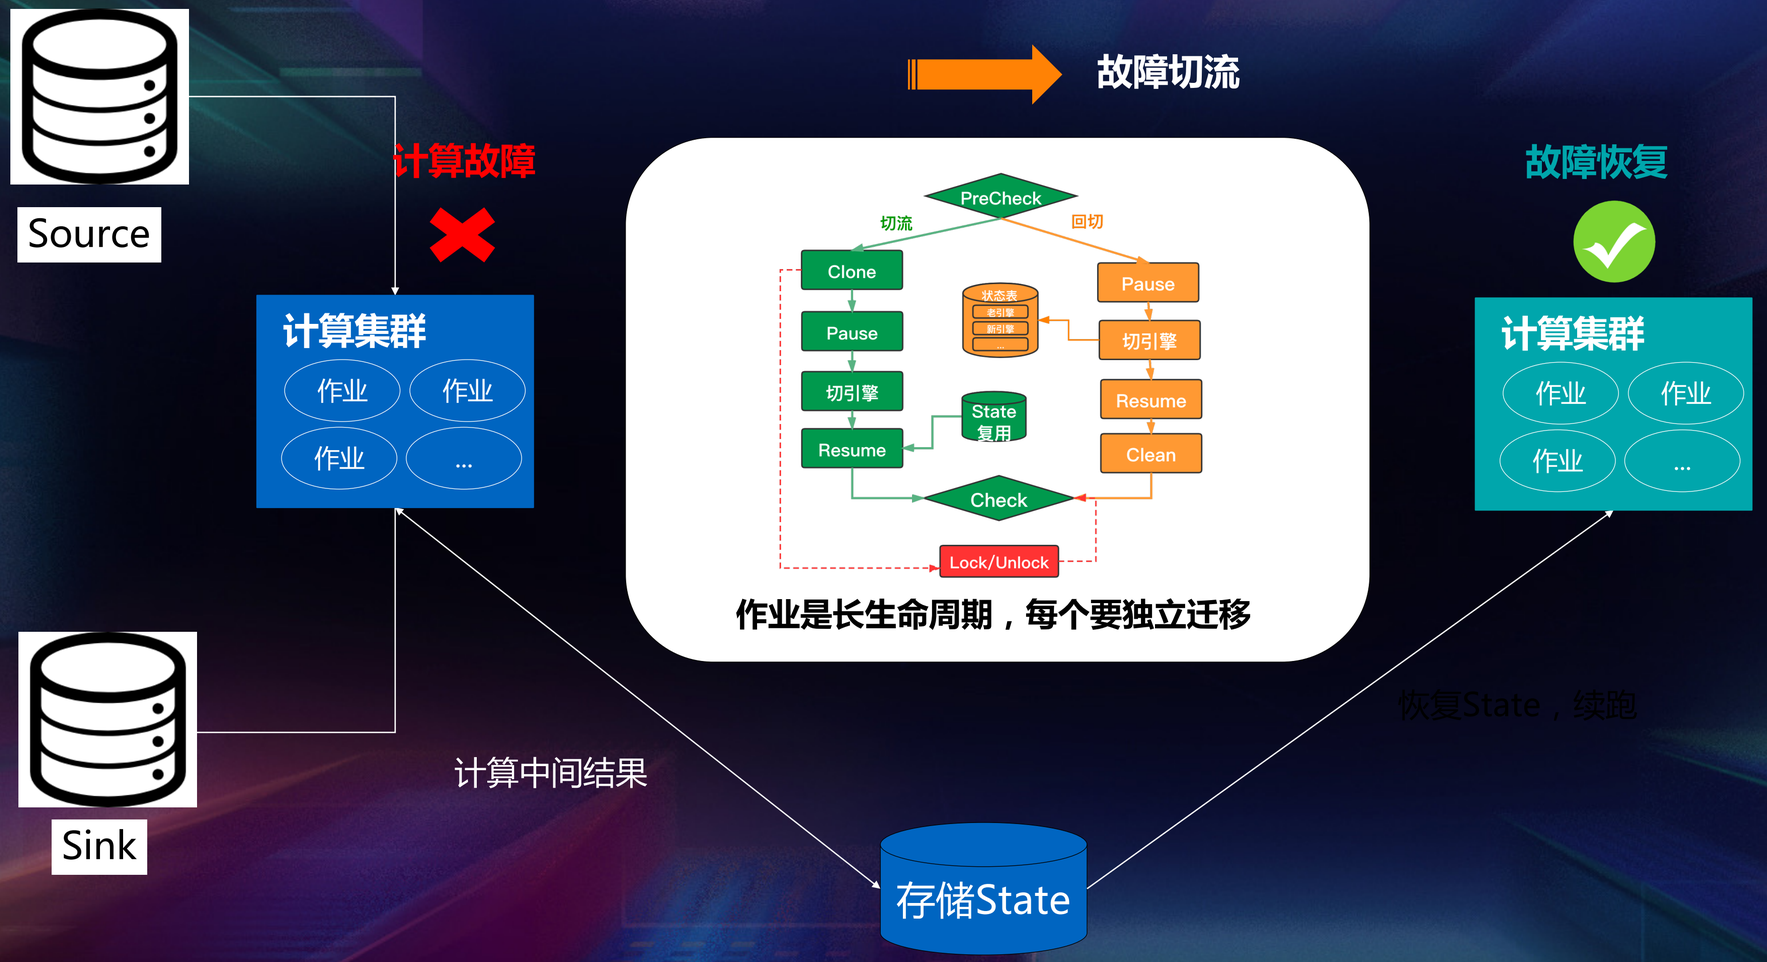


存储复用计算透明迁移，业务无感

3. 怎么透明切？

建设Flink Job快速切流的平台容灾能力，让故障恢复“更确定”

作业大规模切流的技术方案



Flink 双11大促专项保障

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

压测平台

生产到影子链路一键克隆，超大规模
精准造压&控压&稳压能力

业务降级

低优先级作业快速降级/恢复能力，
水位提前预测，精准控制集群水位



计算限流

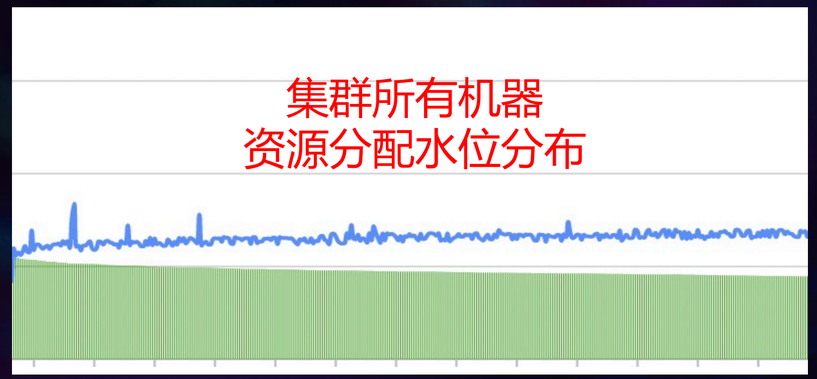
作业pod级cpu资源隔离和限制
实现作业粒度计算精准限流

热点均衡

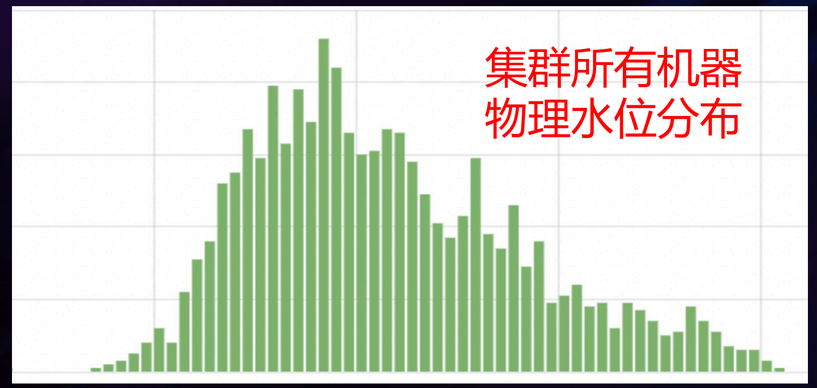
基于大促压测历史数据对作业画像，
实现资源合理配置，集群热点机器均衡

Flink Cluster AutoPilot

集群“卖出”资源和用户“使用”资源存在差异，导致集群层面机器水位不均衡

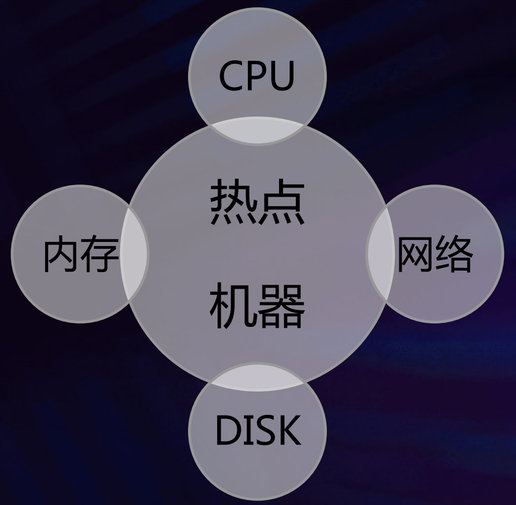


VS



集群水位
不断提升

机器某一维度资源达到性能瓶颈
（e.g cpu > 95%）



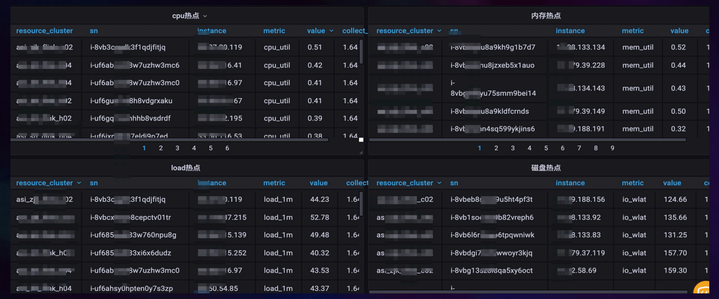
而局部热点机器不仅会影响集群稳定性，还会成为整集群水位提升瓶颈，成本浪费

热点机器既影响稳定性，又影响成本

Flink Cluster AutoPilot

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

1. 发现热点机器



cpu/mem/disk/load热点机器实时监控
（热点机器定义来自SRE线上经验）

2. 分析热点机器





机器诊断工具定位具体进程
（Linux系统原理深入分析）

3. 决策业务策略

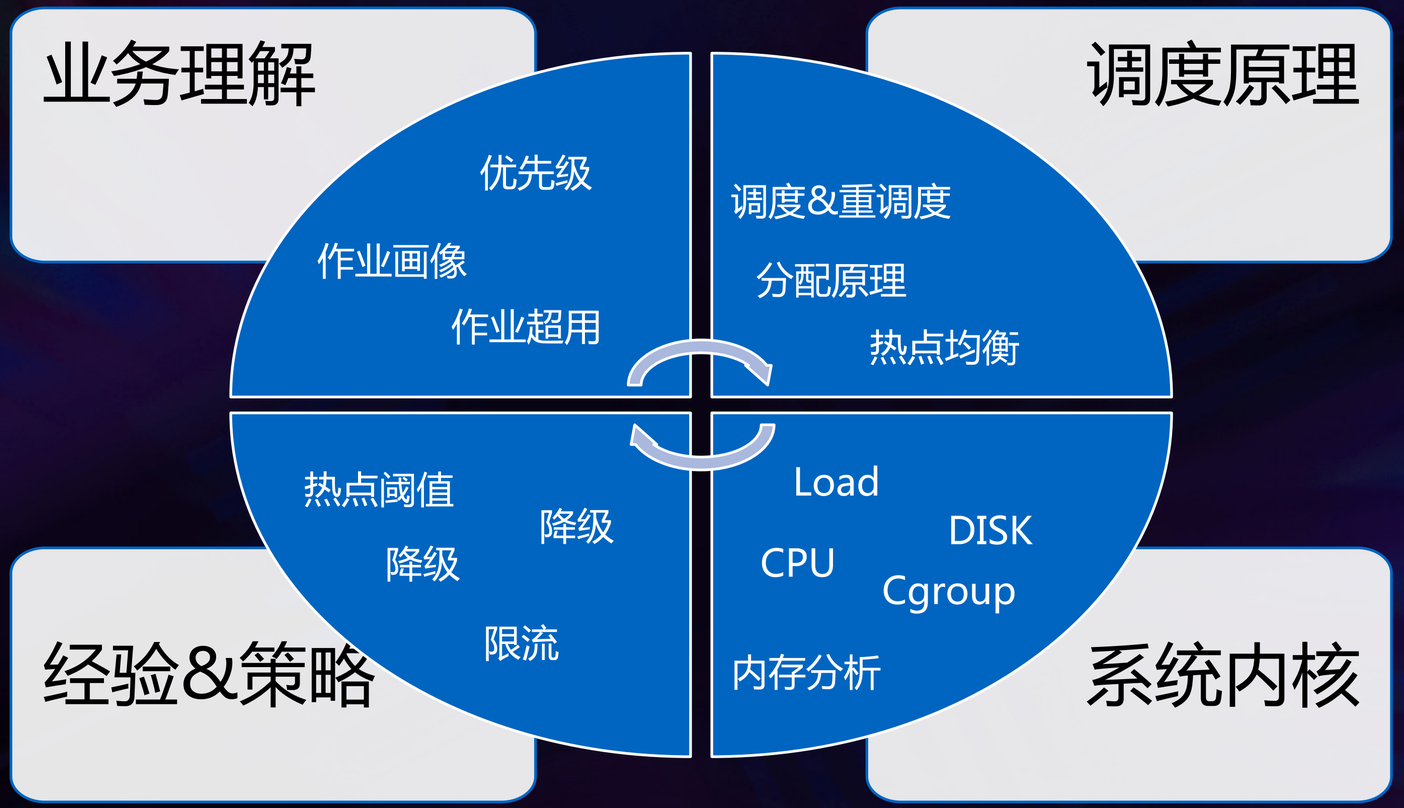


从进程关联业务数据决策
（全链路数据关联以及业务策略）

4. 解决热点机器（限流/均衡/降级）

热点机器分析&解决的复杂流程

Flink Cluster AutoPilot



热点机器背后是涉及 业务&调度&内核&专家经验 全链路分析定界的复杂技术难题

热点机器背后的技术难题

Flink Cluster AutoPilot

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

Flink Cluster AutoPilot

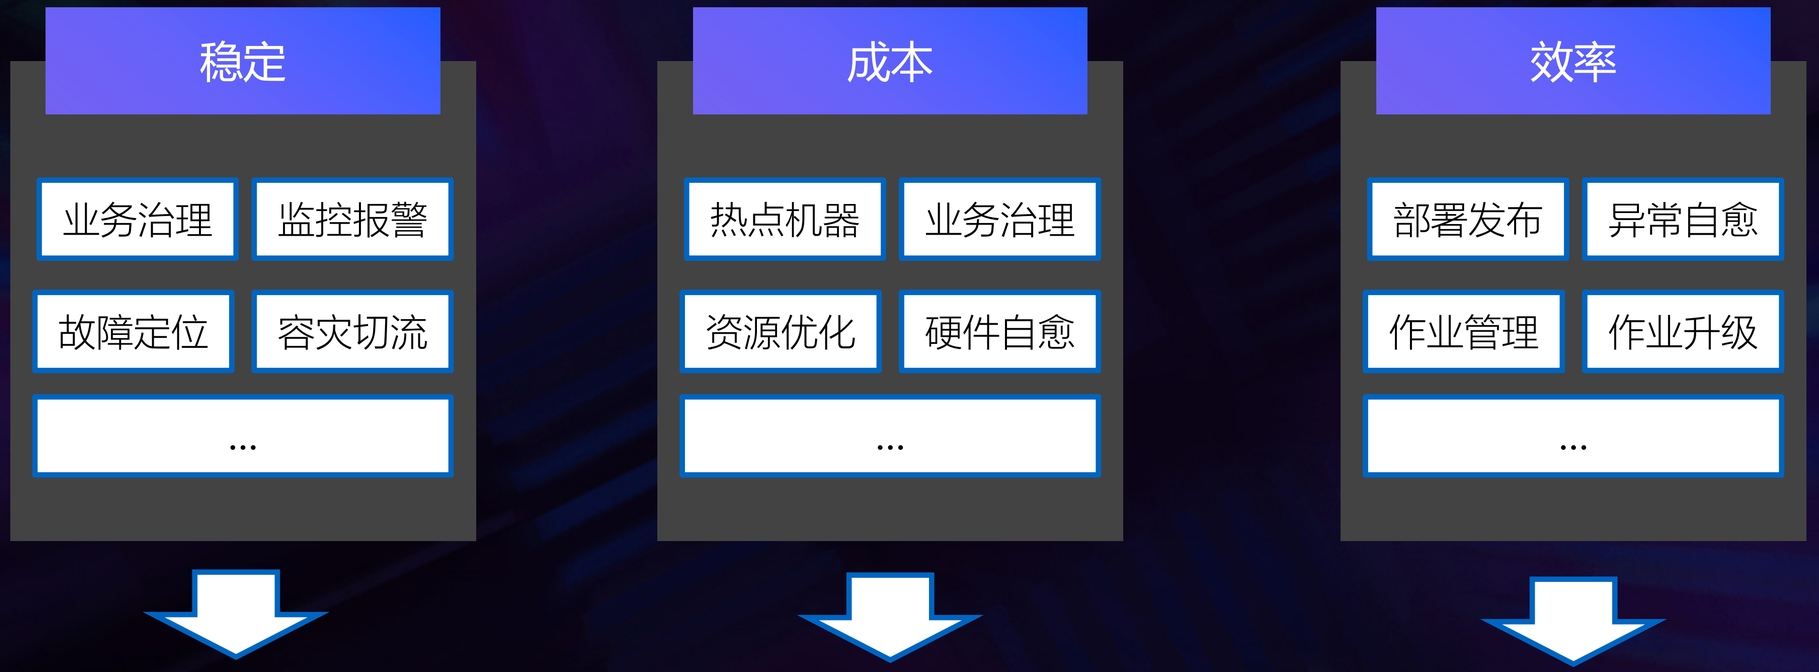
K8S Operator

基于K8S云原生的Flink Cluster AutoPilot实现热点机器自愈



沉淀SRE经验和能力

平台运维能力全面往云原生化演进，运维体系不断升级



基于云原生的Flink Cluster AutoPilot，将运维能力更标准化，更智能化

#3 应用运维Flink Job

实时计算用户面临的运维难题

随着实时计算大趋势，Flink用户和作业数飞速增长且体量庞大，而Flink Job运维是一大复杂难题



将运维丰富经验沉淀为产品



运维丰富的知识+经验+能力

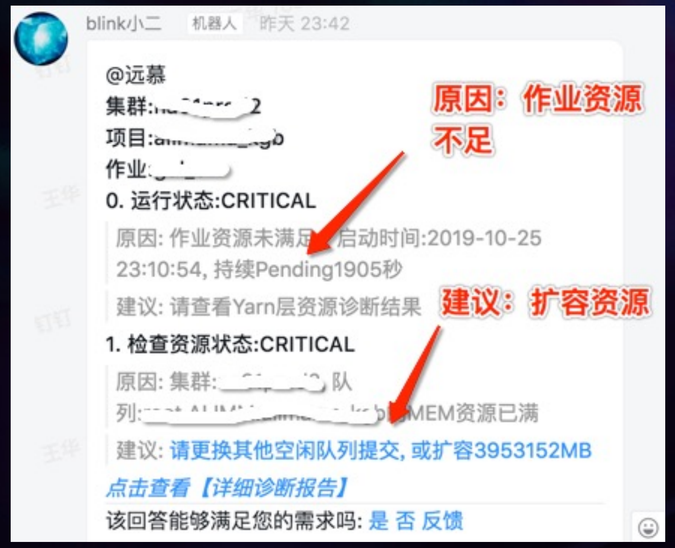


运维产品功能

Flink Job Advisor + Operator 定位和解决作业运维难题

Flink Job Advisor

阿里内部用户每周上千次使用Advisor，自助一键诊断作业疑难杂症



Case1：作业资源不足无法启动



Case2：平台机器下线导致FailOver



Case3：作业内存配置不合理导致OOM

效果展示

Flink Job Advisor

几十种复杂异常诊断能力，构成庞大的决策树



针对Flink Job稳定性问题，提供事前风险体检、事中异常诊断、事后历史回溯全过程一键诊断能力

风险体检
- 指标异动/事件预测异常

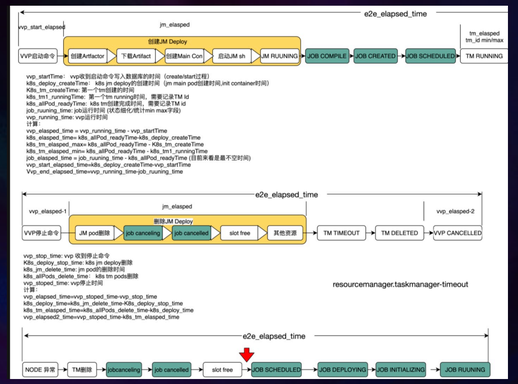
异常诊断
- 启动/停止报错或者慢
- 运行态性能不足/报错/数据问题

历史回溯
- 历史问题诊断快照回溯

背后的大脑：决策树

Flink Job Advisor

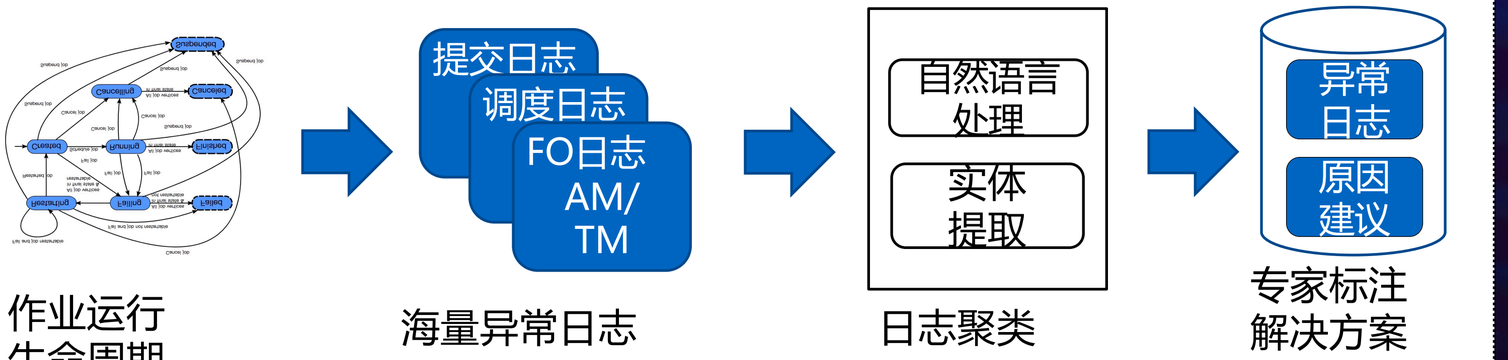
1. 作业状态诊断



2. 运行指标诊断



3. 异常日志诊断



Flink Job Operator

FLINK FORWARD #ASIA 2021 ONLINE 实时即未来 REAL-TIME IS THE FUTURE

升级

作业版本透明升级，配置热快速更新，解决稳定性隐患和异常

优化

作业性能配置调优、资源配置优化，解决性能和成本问题



迁移

作业跨集群透明迁移，帮助用户高效管理多集群大规模体量作业

修复

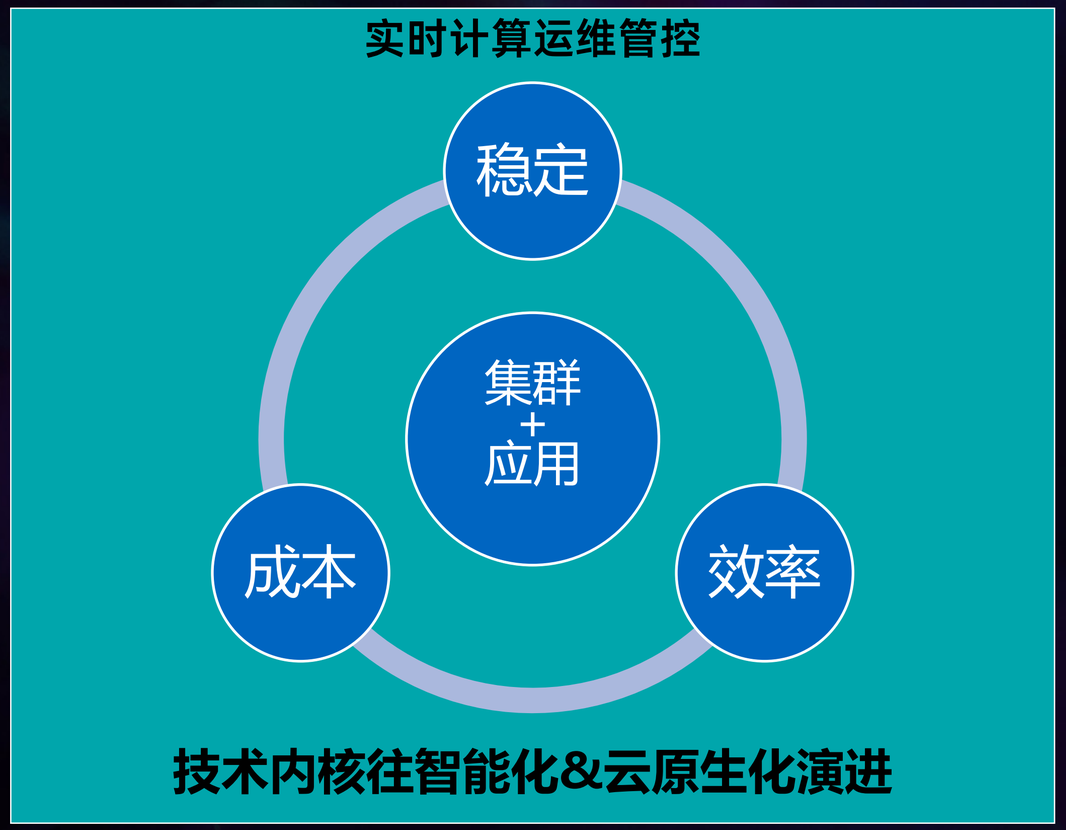
Advisor诊断出的风险和异常一键修复自愈

修复作业问题

实时计算运维体系全貌

SRE+产研+技术支持

实时计算终端用户



以智能+云原生为技术内核，建设实时计算运维管控产品，解决超大规模Flink平台运维&应用运维稳定性、成本、效率三大难题


FLINK FORWARD
#ASIA 2021
ONLINE
实时即未来
REAL-TIME IS THE FUTURE
THANKS